

Planificación del Proyecto Semestral: Análisis con Reducción de Dimensionalidad y Clustering

Integrantes:

Felipe Cubillos (felipe.cubillos.a@usach.cl)
Tomás Cárcamo (tomas.carcamo.g@usach.cl)
Diego Gómez (diego.gomez.g@usach.cl)

Docente: Carolina Zambrano

Asignatura: Análisis de Datos

24 de Julio de 2026

1. Identificación General del Proyecto

- **Dataset seleccionado:** Heart Disease.
- **Fuente del dataset:** UCI Machine Learning Repository.
- **Tipo de problema:** Aprendizaje no supervisado.
- **Tema del análisis:** Análisis con Reducción de Dimensionalidad y Clustering.
- **Objetivo general:** Aplicar técnicas de reducción de dimensionalidad y algoritmos de clustering sobre el "Heart Disease Dataset" para descubrir patrones ocultos, perfiles de agrupamiento y estructuras internas que permitan diferenciar a los pacientes según su diagnóstico coronario.
- **Hipótesis exploratoria:** Dada la naturaleza no supervisada del análisis, se tomará un enfoque exploratorio general para descubrir estructuras locales y agrupamientos que reflejen el estado angiográfico real de los pacientes.

2. Comprensión del Problema

- **Qué fenómeno analizan:** La presencia y diagnóstico de cardiopatías (enfermedad de las arterias coronarias) basados en atributos clínicos y resultados de exámenes.
- **Qué patrones esperan encontrar:** Agrupaciones de pacientes que compartan similitudes en sus niveles de colesterol, presión arterial, anomalías en el ECG y dolor torácico, que idealmente se alineen con la presencia o ausencia de la enfermedad.
- **Por qué es adecuado:** Porque se busca descubrir la estructura interna y los perfiles de los pacientes sin depender exclusivamente de la etiqueta de diagnóstico, validando si las variables por sí solas agrupan a pacientes sanos versus enfermos.
- **Datos a ocupar:** Se utilizará el subconjunto de Cleveland correspondiente a 14 variables de las 76 originales.

Preguntas de análisis:

- **¿Existen grupos naturales...?** Sí, la idea es ver si los sanos ($num = 0$) y los enfermos ($num = 1$) forman clústeres separados.
- **¿Qué técnica separa mejor...?** Se evaluará contrastando PCA con UMAP.
- **¿Qué variables influyen más...?** Probablemente el tipo de dolor torácico (cp), la frecuencia cardíaca (thalach) o la depresión del segmento ST (oldpeak).
- **¿Cómo afecta la reducción...?** Ayudará a visualizar la alta dimensionalidad (14 atributos) en un plano 2D/3D mitigando la maldición de la dimensionalidad.

3. Comprensión de los Datos

Basado en las variables listadas en el informe original:

- **Número de registros:** 303.
- **Número de variables:** 14.
- **Faltantes / Problemáticas:** El informe original menciona que “algunos son marcados como datos faltantes”, particularmente `ca` y `thal`.
- **Tipo predominante:** Numérico entero y decimal.

Variable	Tipo	Descripción
age	Numérica Entera	Edad en años
sex	Categórica	Sexo (1: Masculino, 0: Femenino)
cp	Categórica	Tipo de dolor torácico (1: angina típica, 2: angina atípica, 3: dolor no anginoso, 4: asintomático)
trestbps	Numérica Decimal	Presión arterial en reposo (en mm/Hg)
chol	Numérica Decimal	Colesterol sérico en mg/dl
fbs	Categórica	Glucemia en ayunas (>120 mg/dl) (1: verdadero, 0: falso)
restecg	Categórica	Resultados del ECG en reposo (0: normal, 1: anomalías ST-T, 2: hipertrofia)
thalach	Numérica Entera	Frecuencia cardíaca máxima alcanzada
exang	Categórica	Angina inducida por el ejercicio (1: sí, 0: no)
oldpeak	Numérica Decimal	Depresión del segmento ST inducida por el ejercicio
slope	Categórica	Pendiente del segmento ST (1: ascendente, 2: plana, 3: descendente)
ca	Numérica Entera	Número de vasos principales (0-3) coloreados por fluoroscopia
thal	Categórica	Defecto (3: normal, 6: defecto fijo, 7: defecto reversible)
num	Categórica	Diagnóstico de cardiopatía (0: $<50\%$, 1: $>50\%$)

4. Exploración inicial de Datos

Técnica	Objetivo
Estadística descriptiva	Comprender la tendencia central y dispersión de las variables clínicas.
Histogramas	Analizar la distribución de frecuencias de atributos numéricos.
Boxplots	Identificar anomalías (outliers) en las variables clínicas.
Matriz de Correlación	Cuantificar la dependencia y asociación matemática entre atributos.
Heatmap de Correlación	Visualizar patrones multivariados y detectar posible multicolinealidad.

- **Estadística descriptiva:** Permite resumir indicadores clave como la media, mediana y desviación estándar de variables críticas (como la edad, colesterol o `chol`, y presión arterial o `trestbps`), estableciendo una comprensión base del perfil general de los pacientes.
- **Histogramas:** Facilitan la observación visual de cómo se distribuyen los datos en variables continuas, ayudando a determinar si características como la frecuencia cardíaca máxima (`thalach`) siguen una distribución normal o si presentan sesgos que requieran una transformación previa.
- **Boxplots:** Resultan fundamentales para aislar visualmente valores atípicos (outliers) que podrían distorsionar fuertemente la efectividad de algoritmos basados en distancias como K-Means. Se prestará especial atención a campos propensos a variaciones extremas, como el colesterol o la depresión del segmento ST (`oldpeak`).
- **Matriz de Correlación:** Permite calcular de forma exacta el grado de asociación lineal entre las variables de estudio. Esto es crucial para identificar qué atributos están aportando información redundante al modelo antes de aplicar técnicas no supervisadas.
- **Heatmap de Correlación:** Traduce la matriz matemática a una representación gráfica mediante escalas de color, agilizando la detección visual de variables fuertemente correlacionadas. Esto justifica decisiones metodológicas clave, como qué variables podrían condensarse eficazmente durante la etapa de Reducción de Dimensionalidad (PCA).

5. Plan de Preprocesamiento

- **Tratamiento de nulos:** Sí, se detectarán y tratarán mediante imputación o eliminación.
- **Eliminación de outliers:** Sí.
- **Escalamiento/Estandarización:** Sí, se aplicará para asegurar un rendimiento óptimo de los modelos no supervisados.
- **Codificación categórica:** Sí, a las variables clínicas categóricas.

6. Plan de Reducción de Dimensionalidad

- **Técnica 1: PCA**
 - **Parámetros:** `n_components`.

- **Objetivo:** Analizar la varianza explicada.

■ Técnica 2: UMAP

- **Parámetros:** `n_neighbors`, `min_dist`.
- **Objetivo:** Analizar estructura local y separación visual.

Criterio	PCA	UMAP
Interpretabilidad	Alta, cada componente principal es una combinación matemática exacta de las variables originales.	Baja, al basarse en la topología de colectores y optimización no lineal, los ejes resultantes en el espacio de baja dimensionalidad no tienen significado.
Preservación global	Alta, su objetivo matemático es maximizar la varianza total proyectada.	Media - Alta, a diferencia de t-SNE, que sacrifica casi toda la estructura global, UMAP logra un buen equilibrio.
Preservación local	Baja, No está diseñado para identificar relaciones complejas de vecindad.	Alta, Su diseño fundamental consiste en construir un grafo de vecinos más cercanos en el espacio de alta dimensión y luego optimizar.
Separación visual	Moderada, en conjuntos de datos complejos, PCA tiende a producir visualizaciones que parecen "nubes".	Alta, es excepcional para visualización. Agrupa fuertemente las observaciones similares y empuja lejos a las distintas.
Tiempo computacional	Costo computacional bajo, álgebra lineal simple.	Costo computacional medio, basado en grafos, no es tan caro a diferencia de t-SNE.

7. Plan de Clustering

■ Algoritmo 1: K-Means

- **Hiperparámetro:** `k` (evaluado mediante el método del codo).
- **Objetivo:** Aprovechar que se conocen la cantidad de clusters deseados (2: enfermos o sanos), y el sencillo funcionamiento del algoritmo para particionar los datos en grupos.

■ Algoritmo 2: OPTICS

- **Hiperparámetros:** `min_samples` y `xi` (o `max_eps`).
- **Objetivo:** Detectar clústeres de densidades variables y aislar el ruido de manera robusta. Al no depender de un único valor de densidad global (como el `epsilon` en DBSCAN), OPTICS es ideal para descubrir estructuras complejas y perfiles clínicos atípicos en los que la densidad de agrupamiento fluctúa significativamente.

8. Plan de Hiperparámetros

Algoritmo	Hiperparámetro	Valor
PCA	<code>n_components</code>	2 o 3. Dependerá de la varianza explicada por los componentes principales.
KMeans	<code>k</code> , <code>max-its</code>	K: 2-3, k-means es sensible a la elección de estos valores y tampoco se desea que haya mucha fragmentación de clusters. <code>max-its</code> : 1000
UMAP	<code>n_neighbours</code> , <code>n_components</code> , <code>min_dist</code>	<code>n_neighbours</code> : 10-20, <code>n_components</code> : 2-3, <code>min_dist</code> : 0.1
OPTICS	<code>min_samples</code> , <code>xi</code>	<code>min_samples</code> : 5, <code>xi</code> : 0.05. Se ajustarán empíricamente para capturar correctamente la jerarquía de densidades y aislar los datos atípicos sin fragmentar los clústeres principales.

9. Plan Experimental

Exp.	Reducción	Agrupamiento	Objetivo	Métrica principal
EX1	PCA	K-Means	Disminuir variables para reducir overfitting y agrupar resultados para descubrir patrones.	PCA: Varianza Explicada. KMeans: Silueta, ICH, Dunn, ARI, Davies-Bouldin.
EX2	PCA	OPTICS	Disminuir variables para reducir overfitting y agrupar resultados para descubrir patrones.	PCA: Varianza Explicada. OPTICS: Silueta, ICH, Dunn, ARI, Davies-Bouldin.
EX3	UMAP	K-Means	Disminuir variables para reducir overfitting y agrupar resultados para descubrir patrones.	UMAP: Separación. KMeans: Silueta, ICH, Dunn, ARI, Davies-Bouldin.
EX4	UMAP	OPTICS	Disminuir variables para reducir overfitting y agrupar resultados para descubrir patrones.	UMAP: Separación. OPTICS: Silueta, ICH, Dunn, ARI, Davies-Bouldin.

10. Plan de Evaluación

Métrica	Qué evalúa	Resultado esperado
Silhouette Score	Evalúa la calidad de los grupos (clusters) midiendo la cohesión y la separación.	Se espera un valor lo más cercano posible a 1. Esto indicaría clústeres muy densos y bien separados.
Davies-Bouldin	Mide qué tan compactos y separados están los grupos de datos.	Se espera un valor lo más bajo posible (el mínimo absoluto es 0). Un resultado bajo indica que los grupos son muy compactos internamente y están muy distanciados unos de otros.
Calinski-Harabasz	Evalúa la calidad de los modelos de agrupamiento (clustering) en aprendizaje automático, calculada como la razón entre la dispersión entre grupos y la dispersión dentro de los grupos.	Se espera un valor lo más alto posible. Puntuaciones altas demuestran que la varianza entre los clústeres es mucho mayor que la varianza interna de cada clúster.

Estas métricas fueron seleccionadas para evaluar la calidad de los algoritmos de clustering desde diferentes perspectivas geométricas y estadísticas, permitiendo una validación robusta del aprendizaje no supervisado. Al no depender de etiquetas preexistentes, el rendimiento de los modelos se medirá por su capacidad para estructurar los datos de forma natural. Por lo tanto, se considerará que un modelo y sus respectivos hiperparámetros son óptimos cuando logren maximizar simultáneamente el Silhouette Score y el índice de Calinski-Harabasz, mientras minimizan el índice de Davies-Bouldin. Este equilibrio garantizará la identificación de agrupaciones que sean internamente cohesivas y externamente divergentes.

11. Evaluación Comparativa

Para la evaluación comparativa, se contrastará el rendimiento de K-Means y OPTICS debido a que representan enfoques de agrupamiento geoméricamente opuestos, lo que enriquecerá el análisis exploratorio. Por un lado, K-Means asume clústeres esféricos e isotrópicos, lo que permitirá comprobar si los perfiles clínicos de los pacientes forman grupos compactos y de varianza similar. Por otro lado, OPTICS basa su agrupamiento en la densidad espacial relativa. Esto lo hace ideal para descubrir estructuras complejas, manejar agrupaciones con densidades variables y aislar pacientes atípicos (ruido) que no se ajustan a un diagnóstico estándar.

Criterio	K-Means	OPTICS
Ventajas	Computacionalmente eficiente, fácil de implementar e interpretar. Funciona rápido incluso al evaluar múltiples hiperparámetros (método del codo).	No requiere definir la cantidad de clústeres de antemano. Es capaz de identificar clústeres de densidades variables (mejora directa sobre DBSCAN) y es robusto aislando ruido.
Desventajas	Es muy sensible a valores atípicos (outliers). Asume que los clústeres son esféricos y de tamaño similar, y requiere que se defina K a priori.	Mayor costo computacional y de memoria que K-Means o DBSCAN. La parametrización (ej. parámetro xi) para extraer clústeres del diagrama de alcanzabilidad puede ser compleja.
Calidad del agrupamiento	Produce clústeres compactos. Funciona bien si los perfiles tienen una varianza similar, pero puede forzar agrupaciones artificiales si la estructura real es más compleja.	Excelente para identificar jerarquías de agrupamiento, estructuras no lineales y perfiles atípicos, manteniendo alta calidad sin importar las fluctuaciones en la densidad de los datos.

12. Plan de Visualización y Herramientas

Visualización	Objetivo
PCA 2D / 3D	Dependiendo de la varianza explicada, vamos a poder observar la relación entre las variables de manera gráfica con una clara separación entre puntos.
Clusters coloreados	Comparación de agrupamientos con los datos ya previamente etiquetados. Contrastar con ARI.
Comparación algoritmos	Contrastar entre algoritmos más primitivos (PCA y K-Means) con los más sofisticados (UMAP y OPTICS).
Método del codo	Selección de k.
Gráfico Silhouette	Evaluar cohesión intra grupos.

Elemento	Herramienta
Lenguaje	Python
Librerías	pandas, sklearn, matplotlib
Visualización	seaborn, plotly
Reducción dimensional	umap-learn
Entorno	Jupyter / Colab

Actividad	Responsable	Fecha inicio	Fecha término	Estado	S1	S2	S3	S4	S5	S6	S7	S8	S9
Obtención y Selección de Datos	Tomás	20/07/2026	26/07/2026	Completado									
Limpieza y Exploración (EDA)	Diego	27/07/2026	02/08/2026	Pendiente									
Transformación y Preprocesamiento	Diego	03/08/2026	09/08/2026	Pendiente									
Reducción dimensional	Felipe	10/08/2026	16/08/2026	Pendiente									
Clustering	Felipe	17/08/2026	23/08/2026	Pendiente									
Evaluación	Felipe y Diego	24/08/2026	30/08/2026	Pendiente									
Interpretación e Informe Final	Tomás y Felipe	31/08/2026	13/09/2026	Pendiente									
Presentación Final	Equipo	14/09/2026	20/09/2026	Pendiente									

13. Cronograma del proyecto

14. Referencias

- UCI Machine Learning Repository. (s.f.). Heart Disease Dataset. <https://archive.ics.uci.edu/dataset/45/heart+disease>
- Detrano, R.C., et al. (1989). International application of a new probability algorithm for the diagnosis of coronary artery disease. *The American journal of cardiology*, 64(5), 304-10.
<https://www.semanticscholar.org/paper/International-application-of-a-new-prob-ability-C3%A1nosi/a7d714f8f87bfc41351eb5ae1e5472f0ebbe0574>