

Proyecto Semestral PostParo — Análisis con Reducción de Dimensionalidad y Agrupamiento

1. Descripción general

En este proyecto semestral deberán desarrollar un análisis utilizando técnicas de:

- Reducción de dimensionalidad,
- Agrupamiento (clustering),
- Visualización,

En suma, evaluación de modelos no supervisados.

El trabajo debe aplicar metodologías de análisis de datos sobre una base de datos real de libre disposición.

2. Objetivo general

Aplicar técnicas de reducción de dimensionalidad y clustering para descubrir perfiles de agrupamiento en datos reales.

3. Bases de datos disponibles

Cada grupo trabajara con una de las siguientes bases de datos:

Dataset	Descripción
Heart Disease Dataset	Datos médicos para detección de enfermedad cardíaca (grupos 1, 2, 3, 4,9)
Adult Income Dataset	Datos socioeconómicos para análisis de ingresos (grupos 5, 6, 7, 8,10)

4. Requisitos obligatorios

El proyecto debe incluir:

A. Reducción de dimensionalidad

Aplicar al menos DOS algoritmos:

- PCA
- t-SNE
- UMAP

Debe compararse:

- calidad visual,
- separación de grupos,
- interpretabilidad,
- tiempo computacional.

B. Clustering

Aplicar al menos DOS algoritmos:

- K-Means
- DBSCAN
- Gaussian Mixture Models (GMM), u otro que este en la lista de algoritmos de las diapositivas y apuntes de clases.

Debe compararse:

- calidad de clusters,
- sensibilidad a parámetros (hiperparametros),
- interpretación de grupos.

5. Metodología obligatoria

El proyecto debe seguir una metodología inspirada en KDD:

Eta pa	Actividad
Selección	Obtención del dataset
Limpieza	Tratamiento de datos faltantes y outliers
Transformación	Escalamiento y codificación
Reducción dimensional	PCA / t-SNE / UMAP
Clustering (agrupamiento)	Aplicación de algoritmos
Evaluación	Métricas y visualización
Interpretación	Análisis crítico de resultados

6. Actividades (obligatorias)

Parte 1 — Exploración de datos

Realizar:

1. Descripción de variables
2. Estadística descriptiva
3. Detección de valores faltantes
4. Análisis de correlación
5. Boxplots

6. Histogramas
7. Heatmap de correlación

Parte 2 — Preprocesamiento

Aplicar:

- normalización o estandarización,
- codificación categórica (si es necesario),
- tratamiento de outliers,
- selección de variables.

Debe justificarse cada decisión.

Parte 3 — Reducción de dimensionalidad

Aplicar al menos DOS técnicas.

PCA

Analizar:

- varianza explicada,
- interpretación de componentes.

t-SNE o UMAP

Analizar:

- estructura local,
- separación visual,
- sensibilidad a hiperparámetros.

Parte 4 — Clustering

Aplicar al menos DOS algoritmos.

K-Means

Debe incluir:

- método del codo,
- Silhouette Score,
- interpretación de centroides.

Segundo algoritmo

Opciones:

- DBSCAN
- GMM u otro del listado de algoritmos de ppts y/o guías.

Comparar:

- número de clusters,
- ruido,
- estabilidad,
- forma de clusters.

Parte 5 — Evaluación

Evaluar usando:

Métrica	Descripción
Silhouette Score	Separación y cohesión
Davies-Bouldin	Compactación
Calinski-Harabasz	Separación global

Además:

- comparar algoritmos,
- justificar selección final,
- discutir posibles limitaciones.

Parte 6 — Visualización

Debe incluir:

- PCA 2D
- PCA 3D (opcional)
- visualización de clusters
- comparación entre algoritmos

Parte 7 — Discusión - Interpretación crítica

El informe debe discutir:

1. Diferencias entre PCA, t-SNE y UMAP.
2. Diferencias entre K-Means y algoritmo aplicado por ejemplo DBSCAN/GMM u otro.
3. Sensibilidad a hiperparámetros.
4. Problema de alta dimensionalidad.
5. Limitaciones del clustering.

8. Estructura de Informe final y entrega del código jupyter notebook (50%)

Formato debe incluir:

- introducción,
- metodología,
- resultados,
- visualizaciones,
- discusión,
- conclusiones,
- referencias.

Entregable — Presentación (20%)

Presentación oral:

- 15 minutos,

12. Rúbrica presentación

Criterio	Puntaje
Limpieza y preprocesamiento	15
Reducción dimensional	20
Clustering	20
Evaluación y métricas	15
Visualizaciones	10
Interpretación crítica	15
Calidad	5

Total: 100 puntos