

Entrega 1: Propuesta

Grupo 2 - Análisis de Datos - 19/07/2026

Descripción del Dataset

<https://archive.ics.uci.edu/dataset/45/heart+disease>

"This database contains 76 attributes, but all published experiments refer to using a subset of 14 of them. In particular, the Cleveland database is the only one that has been used by ML researchers to date. The "goal" field refers to the presence of heart disease in the patient. It is integer valued from 0 (no presence) to 4. Experiments with the Cleveland database have concentrated on simply attempting to distinguish presence (values 1,2,3,4) from absence (value 0)."

El Dataset propuesto tiene origen desde una donación hecha el año 1988, por lo general para propósitos académicos relacionados al aprendizaje automático se usa el subconjunto de Cleveland.

Este dataset fue utilizado en un paper llamado *International application of a new probability algorithm for the diagnosis of coronary artery disease* realizado por Detrano, R.C et. al 1989. Donde los resultados fueron la conclusión del algoritmo es útil cuando los sujetos presentan síndromes de dolores de pecho y enfermedades de filamentos intermedios.

Disponemos de:

- 303 filas correspondientes a pacientes
- 14 atributos por paciente, algunos son marcados como datos faltantes.

Objetivo

Objetivo General: Aplicar técnicas de reducción de dimensionalidad y algoritmos de clustering sobre el "Heart Disease Dataset" para descubrir patrones ocultos, perfiles de agrupamiento y estructuras internas que permitan diferenciar a los pacientes según su diagnóstico coronario.

Objetivos Específicos:

- **Preprocesamiento:** Limpiar, escalar y estandarizar los datos clínicos para asegurar un rendimiento óptimo de los modelos no supervisados.
- **Reducción Dimensional:** Implementar y comparar algoritmos de proyección (como PCA y t-SNE/UMAP) para visualizar conjuntos de alta dimensionalidad, evaluando la varianza explicada, la calidad visual y la separación de grupos.
- **Agrupamiento (Clustering):** Descubrir estructuras locales en los pacientes aplicando modelos como K-Means y DBSCAN/GMM, analizando su sensibilidad a hiperparámetros y la interpretabilidad de los centroides.
- **Evaluación y Análisis:** Contrastar la efectividad y la calidad de los clusters generados utilizando métricas especializadas (Silhouette Score, Davies-Bouldin y

Calinski-Harabasz) , desarrollando una interpretación crítica de los resultados frente a la presencia real de cardiopatías.

Variables

Si bien el dataset cuenta con 76 atributos en total, todos los experimentos publicados hacen referencia al uso de un subconjunto de 14 de ellos, los cuales son:

1. #3 (age) - Edad en años
2. #4 (sex) - Sexo (1: Masculino, 0: Femenino)
3. #9 (cp) - Tipo de dolor torácico
 - 1: angina típica
 - 2: angina atípica
 - 3: dolor no anginoso
 - 4: asintomático
4. #10 (trestbps) - Presión arterial en reposo (en mm/Hg al ingreso hospitalario)
5. #12 (chol) - Colesterol sérico en mg/dl
6. #16 (fbs) - Glucemia en ayunas (> 120 mg/dl) (1 = verdadero; 0 = falso)
7. #19 (restecg) - Resultados del electrocardiograma en reposo
 - 0: normal
 - 1: presenta anomalías en la onda ST-T (inversión de la onda T y/o elevación o depresión del segmento ST $> 0,05$ mV)
 - 2: muestra hipertrofia ventricular izquierda probable o definitiva según los criterios de Estes
8. #32 (thalach) - Frecuencia cardíaca máxima alcanzada
9. #38 (exang) - Angina inducida por el ejercicio (1 = sí; 0 = no)
10. #40 (oldpeak) - Depresión del segmento ST inducida por el ejercicio en relación con el reposo.
11. #41 (slope) - Pendiente del segmento ST de ejercicio máximo
 - 1: ascendente
 - 2: plana
 - 3: descendente
12. #44 (ca) - Número de vasos principales (0-3) coloreados mediante fluoroscopia
13. #51 (thal) - (3 = normal; 6 = defecto fijo; 7 = defecto reversible)
14. #58 (num) - Diagnóstico de cardiopatía (estado angiográfico)
 - 0: Estrechamiento del diámetro $< 50\%$
 - 1: Estrechamiento del diámetro $> 50\%$

Hipótesis Exploratoria

Para hipótesis, dada la naturaleza no supervisada del análisis, no sabemos a ciencia cierta que vamos a obtener, por ende se va a tomar un enfoque más general respecto a la hipótesis exploratoria que se va a abordar a lo largo del proyecto.

Planificación

Semana	Etapas (Metodología)	Tareas Específicas	Responsable	Hito (Entregable)
Semana 1	Selección	Obtención del dataset, definición de la propuesta, planteamiento de variables y redacción de la hipótesis exploratoria.	Tomás	Entregable 1 - Propuesta (15%)
Semana 2	Limpieza	Exploración inicial (EDA). Detección y tratamiento de datos faltantes y outliers.	Diego	
Semana 3	Transformación	Aplicación de escalamiento (normalización o estandarización) y codificación categórica de las variables clínicas.	Diego	

Semana 4	Reducción dimensional	Implementación de PCA y t-SNE/UMAP. Análisis de varianza explicada, estructura local y separación visual.	Felipe	
Semana 5	Clustering (agrupamiento)	Aplicación de algoritmos: K-Means (evaluando el método del codo) y DBSCAN o GMM (evaluando número de clusters y ruido).	Felipe	Entregable 2 - Avance (35%)
Semana 6	Evaluación	Cálculo de métricas: Silhouette Score, Davies-Bouldin y Calinski-Harabasz. Generación de visualizaciones en PCA 2D y gráficos de clusters.	Felipe y Diego	
Semana 7-8	Interpretación	Análisis crítico de resultados. Discusión sobre sensibilidad a hiperparámetros, diferencias entre algoritmos y redacción del informe final.	Tomás y Felipe	Entregable 3 - Informe (30%)
Semana 9	Presentación Final	Preparación de material de apoyo visual y ensayo de la exposición oral de 15 minutos.	Equipo	Entregable 4 - Presentación (20%)

Referencias

- UCI Machine Learning Repository. (s.f.). Heart Disease Dataset.
<https://archive.ics.uci.edu/dataset/45/heart+disease>
- Detrano, R.C., Jánosi, A., Steinbrunn, W., Pfisterer, M.E., Schmid, J., Sandhu, S., Guppy, K.H., Lee, S., & Froelicher, V. (1989). International application of a new probability algorithm for the diagnosis of coronary artery disease. *The American journal of cardiology*, 64 5, 304-10.
<https://www.semanticscholar.org/paper/International-application-of-a-new-probability-for-Detrano-J%C3%A1nosi/a7d714f8f87bfc41351eb5ae1e5472f0ebbe0574>