

Planificación del Proyecto Semestral — Análisis con Reducción de Dimensionalidad y Clustering

Esta planificación está basada en la metodología KDD y alineada con los requisitos del proyecto semestral.

Observación: es probable que se agregue aplicación de reglas de asociación y/o análisis discriminante y/o arboles de decisión.

Los siguientes puntos se agregan en la entrega de este informe de planificación.

1. Identificación General del Proyecto

Elemento	Desarrollo
Asignatura	
Docente	
Integrantes	
Fecha	
Dataset seleccionado	Heart Disease / Adult Income
Fuente del dataset	Lugar de descarga
Tipo de problema	Aprendizaje no supervisado
Tema del análisis	Define el grupo
Objetivo general	Define el grupo
Hipótesis exploratoria	Define el grupo

2. Comprensión del Problema

Problema de análisis

Describe:

- Qué fenómeno desean analizar,
- Qué patrones esperan encontrar,
- Por qué el análisis no supervisado es adecuado al objetivo e hipótesis.
- Que datos ocupa en el análisis, todos los datos o un conjunto de los datos.

Preguntas de análisis

Pregunta	Justificación
¿Existen grupos naturales (no generados por algoritmos o IA) en los datos?	
¿Qué técnica separa mejor los datos?	
¿Qué variables influyen más en la formación de clusters?	
¿Cómo afecta la reducción de dimensionalidad?	

3. Comprensión de los Datos

Elemento	Descripción
Número de registros	
Número de variables	
Que Variables son numéricas	
Que Variables son categóricas	
Que Variables con valores faltantes	
Que Variables potencialmente problemáticas	
Tipo de datos predominante	

4. Exploración Inicial de Datos

Visualizaciones Obligatorias

Técnica	Objetivo	Realizado
Estadística descriptiva	Comprender distribución	
Histogramas	Analizar distribución	
Boxplots	Detectar outliers	
Heatmap correlación	Detectar relaciones	
Matriz de correlación	Analizar dependencia entre datos	

5. Plan de Preprocesamiento

Limpieza y transformación

Técnica	¿Se aplicará? Justificación
Eliminación de duplicados	
Tratamiento de nulos	
Eliminación de outliers	
Escalamiento	
Normalización	
Estandarización	
Codificación categórica	
Selección de variables	

6. Plan de Reducción de Dimensionalidad

Técnicas seleccionadas

Debe aplicarse al menos DOS técnicas.

Técnica	Parámetros	Objetivo
PCA	n_components	
t-SNE	perplexity	
UMAP	n_neighbors, min_dist	

Comparación esperada

Criterio	PCA	t-SNE	UMAP
Interpretabilidad			
Preservación global			
Preservación local			
Separación visual			
Tiempo computacional			

7. Plan de Clustering

Algoritmos seleccionados

Debe aplicarse al menos DOS algoritmos. Uno de ellos debe ser K- Means.

Algoritmo	Parámetros	Objetivo
K-Means	K	
Algoritmo 2	Parámetros del algoritmo	

8. Plan de Hiperparámetros

Algoritmo	Hiperparámetro	Valores a probar

9. Plan Experimental

Experimento Técnica Reducción Clustering Objetivo Métrica principal

Experimento 1

Experimento 2

Experimento 3

Experimento 4

10. Plan de Evaluación

Necesita aplicar las Métricas obligatorias

Métrica	Qué evalúa	Resultado esperado
Silhouette Score	Cohesión y separación	
Davies-Bouldin	Compactación	
Calinski-Harabasz	Separación global	

11. Evaluación Comparativa

Comparación de algoritmos

Algoritmo	Ventajas	Desventajas	Calidad del agrupamiento
K-Means			
Algoritmo 2			

12. Plan de Visualización

Visualizaciones obligatorias

Visualización	Objetivo
PCA 2D	Visualizar separación
PCA 3D	Visualización espacial
Clusters coloreados	Comparar agrupamientos
Comparación entre algoritmos	Evaluar separación
Método del codo	Selección de k
Gráfico Silhouette	Evaluar cohesión

13. Herramientas Tecnológicas usadas para el proyecto

Elemento	Herramienta
Lenguaje	Python
Librerías	pandas, sklearn, matplotlib
Visualización	seaborn, plotly
Reducción dimensional	umap-learn
Entorno	Jupyter / Colab

14. Cronograma del Proyecto

En suma, para resumir las actividades planificadas para el proyecto genere la carta Gantt.

Observación: puede agregar mas actividades que las que se sugieren a continuación.

Actividad	Responsable	Fecha inicio	Fecha término	Estado
Obtención de datos				
Limpieza				
Exploración				
Reducción dimensional				
Clustering				
Evaluación				
Visualización				
Informe final				
Presentación				