

Análisis Exploratorio y Minería de Datos sobre Heart Disease Dataset (UCI)

Proyecto ADD – 2026

Felipe

Universidad – Análisis de Datos


11 de agosto de 2026

Contenido

- 1 Limpieza y preprocesamiento
- 2 Reducción dimensional
- 3 Clustering
- 4 Evaluación y métricas
- 5 Visualizaciones
- 6 Interpretación crítica
- 7 Calidad


Exploración inicial (EDA)

- **Dataset:** Heart Disease (UCI, id=45), 303 registros, 14 variables.
- **Target:** Severidad de enfermedad cardíaca (0–4).
- **Variables clave:** age, chol, trestbps, thalach, oldpeak.




Observación: Distribuciones asimétricas en chol y oldpeak; presencia de outliers visibles.

Boxplots y detección de outliers




Boxplots individuales



Boxplots combinados

- chol y oldpeak presentan la mayor cantidad de valores atípicos.
- trestbps y thalach muestran dispersiones controladas.

Matriz de correlación



- Correlaciones moderadas: ninguna supera $|r| > 0,6$ (máx. 0.578 entre oldpeak y slope), descartando multicolinealidad severa.
- ca, thal y oldpeak son las más correlacionadas con el target.

Tratamiento de valores nulos y codificación


Valores nulos detectados:

- `ca`: 4 nulos → imputados con la mediana.
- `thal`: 2 nulos → imputados con la moda.

Codificación de variables categóricas:

- **Binarias** (`sex`, `fbs`, `exang`): mantenidas como 0/1.
- **Multi-categoría** (`cp`, `restecg`, `slope`, `thal`): One-Hot Encoding.
- **Continuas** (`age`, `trestbps`, `chol`, `thalach`, `oldpeak`, `ca`): solo escalado.

Eliminación de outliers (IQR)



- Método IQR ($Q_1 - 1,5 \cdot IQR$, $Q_3 + 1,5 \cdot IQR$) aplicado sobre 5 variables continuas.
- **Resultado:** 19 filas eliminadas (combinadas). Shape final: 284 filas $\times$ 22 columnas (tras one-hot).
- Las cajas verdes (“Después”) muestran distribuciones más limpias y compactas.

Estandarización (StandardScaler)


- Todas las variables fueron escaladas a media $\mu = 0$ y desviación $\sigma = 1$.
- **Justificación:** PCA y algoritmos basados en distancia (OPTICS, k-NN) requieren variables en la misma escala.

Resumen del preprocesamiento


Etapa	Antes	Después
Carga inicial	303×14	–
Imputación de nulos	6 nulos	0 nulos
Eliminación outliers	303 filas	284 filas
One-Hot Encoding	14 columnas	22 columnas
Escalamiento	Escalas heterogéneas	$\mu = 0, \sigma = 1$

PCA: Varianza explicada y Scree Plot

Scree Plot




Varianza por Componente




- **Criterio de Kaiser** (eigenvalue > 1): 10 componentes retenidos (76.8% de varianza acumulada).
- **Umbral 80 %**: Se requieren 11 de 22 componentes – estructura mayoritariamente NO lineal.

PCA: Loadings – contribución de variables




- **PC1:** Dominada por thalach, slope y thal (y, en sentido inverso, por oldpeak, exang y cp_4).
- **PC2:** Pesos fuertes en restecg (alteraciones de reposo) y variables de thal.
- Las variables one-hot del cp y slope tienen contribuciones relevantes en PC3–PC5.

PCA: Proyección 2D



- Varianza explicada en 2D: $\approx 29,5\%$ (PC1 + PC2).
- Las clases de severidad (0–4) no se separan linealmente en las dos primeras componentes.
- Justifica la exploración de métodos no lineales.



UMAP: Hiperparámetros



- Exploración de `n_neighbors` y `min_dist` para balancear estructura local vs. global.
- Configuración final: `n_neighbors=15`, `min_dist=0.1`.

PCA vs. UMAP – Comparación visual

PCA vs UMAP - Heart Disease



- **PCA** (izquierda): estructura global, poca separación entre clases.
- **UMAP** (derecha): revela subgrupos que PCA oculta; preserva mejor la topología local.

Clustering: dos enfoques complementarios

K-Means (particional):

- Asume clusters esféricos, isotrópicos y de tamaño similar.
- Requiere fijar k a priori (método del codo + Silhouette).
- Eficiente; ideal para verificar si los perfiles clínicos forman grupos compactos.

OPTICS (densidad):


- No requiere especificar ε (a diferencia de DBSCAN).
- Maneja clusters de densidad variable y aísla ruido (perfiles atípicos).
- Produce un ordenamiento de puntos (reachability plot) que revela la estructura jerárquica de densidad.

Ambos se aplican sobre las dos proyecciones 2D: **PCA** (EX1, EX2) y **UMAP** (EX3, EX4).

OPTICS: Configuración utilizada


- `min_samples = 5`
- `xi = 0.05` (método de extracción de clusters)
- `max_eps =  $\infty$`

Se aplicó OPTICS sobre dos proyecciones 2D: **PCA** y **UMAP**.



- Clusters detectados en el espacio PCA.
- El ruido (gris) se distribuye principalmente entre los grupos, en zonas de baja densidad.



OPTICS + UMAP



- UMAP revela grupos más compactos y mejor definidos que PCA.
- Menor proporción de ruido en comparación con la proyección lineal.

Reachability Plots


OPTICS: Distancia de Alcance (xi=0.05)



- Los “valles” en el reachability plot indican clusters de alta densidad.
- UMAP (derecha) produce valles más pronunciados y definidos que PCA, lo que sugiere una estructura de densidad más clara.

K-Means: selección de k (método del codo)


EX1: Selección de k - K-Means sobre PCA



EX1: PCA + K-Means



- El codo de la inercia sugiere $k \approx 4-5$ en ambas proyecciones.
- Criterios complementarios: **Silhouette** y **Davies-Bouldin** confirman el rango ($k = 4$ en PCA, $k = 2$ en UMAP).

EX3: Selección de k - K-Means sobre UMAP




EX3: UMAP + K-Means

K-Means: gráfico Silhouette (k óptimo)




- **PCA** ($k = 4$): Silhouette media 0.447, clusters de tamaño balanceado.
- **UMAP** ($k = 2$): Silhouette media 0.641, clusters muy compactos y separados (coherente con la estructura no lineal).

EX1: K-Means sobre PCA ($k = 4$)




- **Cluster 1** (jóvenes, 49 años, thalach alto): 92 % de pacientes sanos.
- **Clusters 0 y 3** (oldpeak elevado, thalach bajo): mayor proporción de severidad 1–3.
- Los centroides (X) se reconstruyeron al espacio original para interpretar cada perfil.

EX3: K-Means sobre UMAP ($k = 2$)



- La partición en 2 grupos (sano / enfermo, hipótesis inicial del plan) es la más compacta de todas (Silhouette = 0,641).
- Silhouette perfecta: los grupos no se traslapan en el espacio UMAP.
- Los clusters no coinciden con los 5 niveles de severidad ($ARI \approx 0$): agrupan por perfil clínico, no por etiqueta.

Métricas de preservación topológica



Métricas calculadas:

- **Trustworthiness:** ¿Cuán fiel es la vecindad en el espacio reducido?
- **Continuity:** ¿Se preservan todas las vecindades originales?
- **Jaccard k-NN:** Solapamiento de vecinos entre espacio original y reducido.
- **Spearman ρ :** Correlación de distancias.

Resultados clave

- **UMAP supera a PCA** en la mayoría de métricas de preservación topológica.
- **Trustworthiness y Jaccard:** UMAP preserva mejor las vecindades originales.
- **Silhouette:** UMAP produce estructuras más compactas y separables.
- **Spearman ρ :** PCA mantiene mejor la correlación global de distancias (ventaja lineal esperada).


Conclusión: Para este dataset con estructura no lineal, UMAP es superior como paso previo al clustering.

Resultados del clustering (EX1–EX4)

Modelo	k / cl.	Silhouette	Davies-Bouldin	Calinski-Harabasz	ARI	NMI
K-Means PCA	4	0.447	0.788	338.2	0.177	0.219
K-Means UMAP	2	0.641	0.378	440.8	−0,086	0.064
OPTICS PCA	20	0.546	0.568	506.9	0.038	0.223
OPTICS UMAP	27	0.567	0.552	2194.1	0.036	0.207

- **K-Means + UMAP** ($k = 2$) maximiza Silhouette y minimiza Davies-Bouldin: clusters compactos y separados.
- **OPTICS + UMAP** detecta 27 grupos densos (16.5 % de ruido) con la mayor Calinski-Harabasz.
- El **ARI/NMI bajo** en todos los modelos indica que los clusters agrupan por perfil clínico y no por el nivel de severidad etiquetado.


Comparación visual de métricas



- Valores normalizados (min-max por métrica) para comparar escalas distintas.
- **K-Means UMAP** domina en las métricas intrínsecas de compactidad (Silhouette, Davies-Bouldin, Dunn).
- **OPTICS UMAP** domina en Calinski-Harabasz (separación global) por su alta cantidad de clusters.
- El ruido de OPTICS (39.1 % en PCA) degrada su utilidad en la proyección lineal.

Resumen visual del flujo de trabajo

- 1 **EDA:** Histogramas, boxplots y heatmap de correlación para entender la distribución y relaciones entre variables.
- 2 **Preprocesamiento:** Comparativa antes/después de eliminación de outliers.
- 3 **Reducción:** Scree plot, loadings, proyecciones 2D (PCA y UMAP).
- 4 **Clustering:** Visualización de clusters K-Means (EX1, EX3) y OPTICS (EX2, EX4) sobre PCA y UMAP, reachability plots.
- 5 **Evaluación:** Barras comparativas de métricas PCA vs. UMAP.



Interpretación crítica del análisis

Fortalezas:

- El pipeline de preprocesamiento es completo: imputación, codificación, detección de outliers y estandarización.
- La comparación PCA vs. UMAP es objetiva, respaldada por 5 métricas cuantitativas.
- OPTICS es una elección metodológica sólida para datasets con densidad variable.

Limitaciones:

- **Dimensionalidad:** Con solo $\approx 29,5\%$ de varianza en 2D, PCA pierde mucha información. Se usó 2D por visualización, no por optimalidad.
- **Tamaño muestral:** 284 registros es limitado para clustering basado en densidad.
- **UMAP es estocástico:** Los resultados pueden variar entre ejecuciones si no se fija `random_state`.
- **Validación externa débil:** ARI/NMI bajos en todos los modelos: los clusters no replican las etiquetas de severidad (0–4), que además no definen clases “naturales” bien separadas.

Lecciones aprendidas

- La estructura no lineal del dataset (requiere 12 PCs para el 80 % de varianza) justifica plenamente el uso de UMAP.
- El preprocesamiento (outliers + escalado) tiene un impacto directo en la calidad de las proyecciones.
- Las métricas de preservación topológica son complementarias: una sola métrica no basta para decidir entre técnicas de reducción.
- **K-Means** y **OPTICS** sobre UMAP superan a sus versiones sobre PCA: el espacio no lineal revela grupos más compactos.
- La baja concordancia con el target (ARI/NMI) sugiere que la severidad 0–4 no forma grupos geoméricamente “naturales”.

Trabajo futuro

- Explorar $n = 3$ componentes en PCA/UMAP para reducir pérdida de información.
- Refinar la validación externa binaria (sano vs. enfermo) en lugar de los 5 niveles de severidad.
- Probar t-SNE y GMM (modelos de mezcla) como alternativas a UMAP y K-Means.

Evaluación de la calidad del análisis

Calidad de los datos:

- Solo 6 valores nulos en 303 registros (1.98 %) – dataset de alta completitud.
- 19 outliers detectados y eliminados (6.3 % de las filas) con criterio IQR justificado.
- Estandarización verificada ($\mu \approx 0$, $\sigma \approx 1$).

Calidad de la reducción dimensional:

- PCA: scree plot y varianza acumulada documentados. Loadings interpretados.
- UMAP: hiperparámetros explorados y justificados.
- Comparación objetiva con 5 métricas independientes.

Calidad del clustering:

- K-Means: selección de k documentada con método del codo, Silhouette, Davies-Bouldin y Calinski-Harabasz.
- OPTICS configurado con parámetros estándar y documentados; Silhouette reportada sin ruido.
- Evaluación cruzada con 6 métricas (Silhouette, DB, CH, ARI, NMI, Dunn) y centroides interpretados en unidades clínicas.

- **Código fuente** completo en Python (scripts y notebook).
- **Semillas fijas** (`random_state=42`) en PCA, UMAP, KMeans y OPTICS.
- **5 métricas** para comparar PCA vs. UMAP – decisión basada en evidencia, no en preferencia visual.
- **Pipeline documentado** paso a paso: carga → EDA → limpieza → codificación → escalado → reducción → clustering → evaluación.

Gracias